Rasya Gonawi

5054251032

## 1. Tujuan Praktikum

Praktikum ini bertujuan membandingkan kinerja algoritma Random Forest dalam mendeteksi transaksi fraud pada dataset dengan ketidakseimbangan kelas yang tinggi. Tiga pendekatan yang diuji adalah Random Forest tanpa penanganan khusus, Random Forest dengan pembobotan kelas (class_weight), dan Random Forest dengan oversampling SMOTE.

## 2. Data Understanding

Dataset creditcard.csv terdiri atas 284.807 transaksi dan 31 kolom. Kolom Class merupakan target klasifikasi, dengan nilai 0 untuk transaksi normal dan 1 untuk fraud. Fitur masukan terdiri dari Time, Amount, dan V1–V28. Hasil pemeriksaan df.info() menunjukkan seluruh kolom memiliki 284.807 nilai non-null, sehingga tidak ditemukan missing value pada dataset.

| Kelas | Jumlah transaksi | Persentase |
|---|---|---|
| Normal (0) | 284.315 | 99,8273% |
| Fraud (1) | 492 | 0,1727% |

Perbedaan proporsi ini menunjukkan class imbalance yang ekstrem. Oleh karena itu, accuracy saja tidak cukup; evaluasi juga harus mempertimbangkan precision, recall, F1-score, ROC-AUC, dan Average Precision pada kelas fraud.

## 3. Pembagian Data dan Preprocessing

Dataset dipisahkan menjadi 80% data latih dan 20% data uji menggunakan train_test_split dengan random_state=42 dan stratify=y. Stratifikasi menjaga proporsi fraud relatif sama pada kedua bagian. Pemisahan dilakukan sebelum oversampling untuk menghindari kebocoran data sintetis ke data uji.

| Bagian | Jumlah data | Jumlah fraud | Proporsi fraud |
|---|---|---|---|
| Data latih | 227.845 | 394 | 0,1729% |
| Data uji | 56.962 | 98 | 0,1720% |

Baseline dan model class_weight menggunakan fitur tanpa scaling. Pada eksperimen SMOTE, StandardScaler di-fit hanya pada data latih, kemudian digunakan untuk mentransformasi data latih dan data uji. SMOTE hanya diterapkan pada data latih sehingga jumlah kelas normal dan fraud masing-masing menjadi 227.451 sampel. Data uji tetap dalam distribusi aslinya.

## 4. Metode Klasifikasi

Ketiga model menggunakan RandomForestClassifier dengan 100 pohon (n_estimators=100), random_state=42, dan n_jobs=-1. Perbedaannya terletak pada perlakuan terhadap kelas minoritas:

Model pertama merupakan baseline tanpa penanganan imbalance. Model kedua menggunakan class_weight="balanced" untuk meningkatkan bobot kesalahan pada kelas yang lebih jarang. Model ketiga menggunakan SMOTE untuk membuat sampel sintetis kelas fraud pada data latih yang telah diskalakan.

## 5. Hasil dan Perbandingan Model

| Metrik | Baseline | class_weight | SMOTE |
|---|---|---|---|
| Accuracy | 0,9996 | 0,9995 | 0,9995 |

| | | | |
|---|---|---|---|
| Precision fraud | 0,9412 | 0,9605 | 0,8710 |
| Recall fraud | 0,8163 | 0,7449 | 0,8265 |
| F1-score fraud | 0,8743 | 0,8391 | 0,8482 |
| ROC-AUC | 0,9630 | 0,9529 | 0,9684 |
| Average Precision | 0,8734 | 0,8542 | 0,8724 |

Seluruh model menghasilkan accuracy di atas 99,9%, tetapi metrik kelas fraud memperlihatkan perbedaan yang lebih bermakna. Baseline memiliki F1-score dan Average Precision tertinggi, class_weight menghasilkan precision tertinggi, sedangkan SMOTE menghasilkan recall dan ROC-AUC tertinggi.

## 6. Analisis Confusion Matrix

| Model | TP: fraud terdeteksi | FN: fraud terlewat | FP: normal ditandai fraud |
|---|---|---|---|
| Baseline | 80 | 18 | 5 |
| class_weight | 73 | 25 | 3 |
| SMOTE | 81 | 17 | 12 |

Dari 98 transaksi fraud pada data uji, baseline mendeteksi 80 kasus dan melewatkan 18 kasus. Model class_weight mengurangi false positive menjadi 3, tetapi melewatkan 25 fraud. SMOTE berhasil mendeteksi 81 fraud, satu kasus lebih banyak dari baseline, namun false positive bertambah dari 5 menjadi 12. Dengan demikian, peningkatan recall SMOTE disertai kenaikan jumlah alarm palsu.

## 7. Pembahasan

Hasil menunjukkan bahwa teknik penanganan class imbalance tidak otomatis meningkatkan seluruh metrik. Dibanding baseline, class_weight lebih konservatif dalam menandai transaksi sebagai fraud, sedangkan SMOTE sedikit meningkatkan sensitivitas dengan konsekuensi lebih banyak transaksi normal salah diklasifikasikan.

Accuracy yang tinggi perlu ditafsirkan secara hati-hati, karena sekitar 99,83% data merupakan transaksi normal. Bahkan prediksi seluruh transaksi sebagai normal dapat menghasilkan accuracy sekitar 99,83% tanpa mendeteksi satu pun fraud. Selain itu, data uji hanya berisi 98 kasus fraud, sehingga satu kasus mengubah recall sekitar 1,02 poin persentase. Seluruh hasil masih menggunakan threshold klasifikasi bawaan 0,5 dan belum mencakup optimasi threshold atau pengujian berulang.

## 8. Kesimpulan

Random Forest baseline memberikan hasil paling seimbang berdasarkan F1-score fraud (0,8743) dan Average Precision (0,8734). Model dengan class_weight memperoleh precision tertinggi (0,9605), tetapi recall terendah. SMOTE mencapai recall tertinggi (0,8265) dan ROC-AUC tertinggi (0,9684), walaupun jumlah false positive meningkat. Pemilihan model sebaiknya mempertimbangkan konsekuensi kasus fraud yang terlewat dan biaya pemeriksaan terhadap transaksi normal yang salah ditandai sebagai fraud.