LAPORAN PRAKTIKUM 2: PRAPROSES DATA

Nama: Rasya Gonawi

NRP: 5054251032

Mata Kuliah: Data Mining

1. Pendahuluan

Praktikum ini bertujuan untuk mempersiapkan dataset agar siap digunakan untuk analisis atau pemodelan Machine Learning. Dataset yang digunakan adalah House Prices - Advanced Regression Techniques dari platform Kaggle (file train.csv). Dataset ini awalnya memiliki 1460 baris dan 81 atribut yang mencakup berbagai informasi detail terkait karakteristik rumah dan harga jualnya (SalePrice). Tahapan praproses yang dilakukan meliputi pembersihan data, penanganan outlier, transformasi fitur, dan reduksi dimensi.

2. Langkah-Langkah dan Hasil Praproses Data

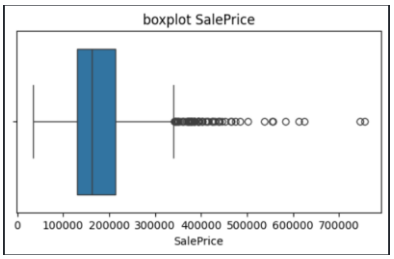
2.1. Pembersihan Data (Data Cleaning)

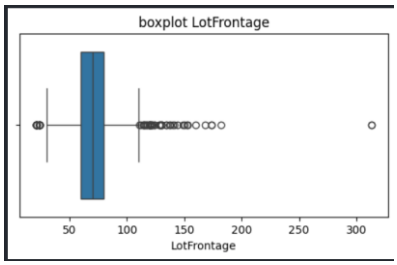
Pembersihan data dimulai dengan mendeteksi missing values (nilai yang hilang) di seluruh kolom. Berdasarkan hasil deteksi, terdapat beberapa kolom yang memiliki tingkat kekosongan data lebih dari 50%, sesuai dengan instruksi, kolom-kolom yang didominasi oleh nilai kosong ini dihapus dari dataset karena dianggap tidak dapat memberikan kontribusi informasi yang cukup valid. Walau sebenernya fitur PoolQC, Fence, Alley seharusnya tidak di buang, karena sesuai deskripsi data, fitur ini kosong karena rumah tersebut memang tidak memiliki fitur fitur tersebut. namun karena intruksi ingin data kosong diatas 50% dihapus, jadi tetap dihapus.

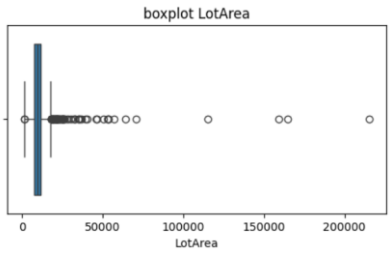
Untuk sisa kolom yang memiliki tingkat missing values ringan, data ditangani melalui proses imputasi agar dataset menjadi utuh. Imputasi yang dilakukan pun berbeda setiap fiturnya, LotFrontage digroup dengan fitur Neighborhood karena memiliki korelasi yang tinggi sehingga imputasi berdasarkan dari fitur Neigborhood, lalu diambil mediannya karena tahan terhadap outlier. Lalu fitur fitur yang memang karena rumah tersebut tidak memilikinya di isi dengan “NoBasement” sebagai contoh. Selain itu, kolom identitas seperti Id dihapus karena tidak memiliki nilai analitik.

2.2. Deteksi dan Penanganan Outlier

Deteksi outlier dilakukan pada atribut numerik menggunakan perhitungan statistik IQR (Interquartile Range) serta divisualisasikan melalui Boxplot. Hasil deteksi menunjukkan bahwa sejumlah besar fitur numerik (seperti LotArea, GrLivArea, dan SalePrice) memiliki pencilan.







Keputusan Penanganan: Outlier yang terdeteksi tidak langsung dihapus. Sebagian besar outlier pada fitur numerik dipertahankan karena dianggap valid secara logika domain (misalnya rumah mewah memang wajar memiliki luas area dan harga yang ekstrem). Penghapusan outlier secara agresif berisiko menghilangkan variasi data yang krusial untuk prediksi regresi di masa depan. Untuk fitur yang bernilai ekstrem karena didominasi oleh angka nol (seperti PoolArea atau ScreenPorch), solusinya adalah melakukan feature engineering dengan membuat variabel biner (contoh: HasPool). Lalu dilakukan juga log transformation untuk fitur fitur yang memiliki skewness tinggi seperti ['MiscVal', 'LotArea', '3SsnPorch', 'LowQualFinSF' 'BsmtFinSF2', 'ScreenPorch', 'EnclosedPorch', 'MasVnrArea', 'OpenPorchSF', 'LotFrontage', 'BsmtFinSF1', 'WoodDeckSF', '1stFlrSF', 'GrLivArea', '2ndFlrSF'] Untuk mengurangi skewness dan Ketika di lakukan encoding Standarisasi nantinya, datanya tidak melenceng.

2.3. Transformasi Data

Transformasi data dilakukan dalam beberapa tahap untuk menstandarkan dan mengoptimalkan bentuk fitur:

1. Log Transformation: seperti yang ditulis diatas fitur numerik yang memiliki kemiringan distribusi yang tinggi (highly skewed), seperti LotArea dan 1stFlrSF, ditransformasi menggunakan fungsi logaritma np.log1p(). Ini berhasil mengubah bentuk distribusi menjadi lebih simetris (normal-like).

	sebelum	sesudah
MiscVal	5.03	5.02
LotArea	-0.74	-0.80
3SsnPorch	7.63	7.62
LowQualFinSF	7.32	7.31
BsmtFinSF2	2.43	2.43
ScreenPorch	3.12	3.12
EnclosedPorch	2.06	2.05
MasVnrArea	0.40	0.40
OpenPorchSF	-0.18	-0.19
LotFrontage	-1.46	-1.53
BsmtFinSF1	-0.75	-0.76
WoodDeckSF	0.09	0.09
1stFlrSF	-0.09	-0.11
GrLivArea	-0.19	-0.21
2ndFlrSF	0.28	0.27

2. Normalisasi/Standarisasi: Untuk memastikan semua variabel numerik memiliki skala yang setara (rata-rata 0 dan standar deviasi 1), dilakukan standarisasi menggunakan StandardScaler.

3. Encoding Atribut Kategoris: Kolom yang bersifat kategorik nominal (seperti Neighborhood dan SaleType) diproses menggunakan One-Hot Encoder, sedangkan kategori yang memiliki tingkatan ordinal (seperti ExterQual atau BsmtQual) ditransformasi menjadi angka terurut menggunakan OrdinalEncoder. Transformasi ini dikelola secara rapi menggunakan Pipeline/ColumnTransformer.

	LotFrontage	LotArea	OverallQual	OverallCond	YearBuilt	YearRemodAdd	MasVnrArea
0	-0.231877	-0.207142	0.651479	-0.517200	1.050994	0.878668	0.514104
1	0.437043	-0.091886	-0.071836	2.179628	0.156734	-0.429577	-0.570750
2	-0.098093	0.073480	0.651479	-0.517200	0.984752	0.830215	0.325915
3	-0.454850	-0.096897	0.651479	-0.517200	-1.863632	-0.720298	-0.570750
4	0.615421	0.375148	1.374795	-0.517200	0.951632	0.733308	1.366489

2.4. Reduksi Dimensi Proses One-Hot Encoding membuat jumlah kolom menjadi lebih dari 200 kolom. Oleh karena itu, dilakukan reduksi dimensi melalui dua pendekatan:

a. Analisis Korelasi (Menghindari Multikolinearitas)

Dilakukan identifikasi fitur-fitur yang saling berkorelasi tinggi secara absolut (> 0.85) menggunakan visualisasi Heatmap.

	Fitur A	Fitur B	Korelasi
0	Street_Grvl	Street_Pave	1.0000
1	Exterior1st_CBlock	Exterior2nd_CBlock	1.0000
2	BldgType_Duplex	MSSubClass_90	1.0000
3	CentralAir_N	CentralAir_Y	1.0000
4	PoolArea	HasPool	0.9897
5	SaleType_New	SaleCondition_Partial	0.9868
6	BldgType_2fmCon	MSSubClass_190	0.9834
7	Exterior1st_VinylSd	Exterior2nd_VinylSd	0.9775
8	Exterior1st_CemntBd	Exterior2nd_CmentBd	0.9742
9	Exterior1st_MetalSd	Exterior2nd_MetalSd	0.9731
10	HouseStyle_SLvl	MSSubClass_80	0.9423
11	HouseStyle_1.5Fin	MSSubClass_50	0.9409
12	RoofStyle_Gable	RoofStyle_Hip	0.9335
13	HouseStyle_1.5Unf	MSSubClass_45	0.9252
14	ScreenPorch	HasScreenPorch	0.9197
15	Exterior1st_HdBoard	Exterior2nd_HdBoard	0.8833
16	GarageCars	GarageArea	0.8825
17	EnclosedPorch	HasEnclosedPorch	0.8816
18	MSZoning_FV	Neighborhood_Somerst	0.8628
19	Exterior1st_Wd Sdng	Exterior2nd_Wd Sdng	0.8592

Hasilnya, beberapa pasangan atribut ditemukan memuat informasi yang sama (misalnya variabel tentang luas garasi dan kapasitas mobil garasi). Salah satu dari fitur redundan tersebut secara sistematis di-drop dari dataset untuk menghindari multikolinearitas.

b. Principal Component Analysis (PCA)

Untuk mengatasi masalah Curse of Dimensionality dan mengompres informasi dari matriks sparse (akibat One-Hot Encoding), diaplikasikan metode PCA. PCA diatur untuk mempertahankan 95% dari total varians data asli (n_components=0.95). Algoritma ini berhasil menyusutkan ratusan dimensi awal menjadi sekumpulan Principal Components yang jauh lebih efisien, tanpa kehilangan karakteristik krusial dari data perumahan tersebut.

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8	PC9
0	-2.362360	-0.317987	-0.631844	-3.133173	-0.650565	0.587876	1.420894	0.093749	0.248830
1	-0.917558	-3.466428	-0.381003	-0.526198	-0.959251	-0.209866	-0.481599	1.919526	0.166300
2	-2.964508	-0.519175	-0.137577	-2.689773	1.059490	-0.481081	-1.181974	-0.264749	0.831066
3	0.978043	-2.031713	1.639035	-1.045283	-1.378010	-0.028273	-1.548755	0.055454	0.344176
4	-4.964725	-0.343195	1.834210	-1.994021	0.826029	-0.146257	-1.111084	-0.272303	0.130311

5 rows × 55 columns

3. Ringkasan Dataset Akhir

Setelah melewati seluruh tahap (cleaning, imputasi, transformasi, hingga PCA), dataset akhir berhasil disatukan kembali bersama kolom target SalePrice. Dataset yang sebelumnya kotor dan didominasi teks serta missing value, kini telah menjadi dataframe berformat numerik murni (kumpulan Principal Component) yang terkompresi dengan baik. Dataset akhir ini bebas dari nilai hilang, dan secara dimensi sudah disederhanakan tanpa mengurangi esensi informasi (95% variance retained).