

Laporan Analisis

Nama: Rasya Gonawi

NRP: 5054251032

1. Deskripsi Dataset

Dataset ini discraping dari website Wikipedia menggunakan requests dan BeautifulSoup. dimana dataset ini Adalah data penemuan eksoplanet (planet di luar tata surya) untuk tahun penemuan 2014 dan 2016, Dataset awal berukuran 2.367 baris dan 12 kolom, yang Dimana setiap kolom Adalah sebagai berikut : Name, Mass (MJ), Radius (RJ), Period (days), Semi-major axis (AU), Temp. (K)[1], Discovery method, Distance (ly), Host star mass ($M_{\odot}$), Host star temp. (K), Remarks, dan Discovery_Year.

2. Data Preprocessing dan Cleaning

Permasalahan: 11 dari 12 atribut terdeteksi bertipe object (karena adanya karakter non-numerik seperti bracket sitasi [1], [2] serta tanda plus-minus $\pm$). Sehingga perlu untuk diperbaiki penulisan nya

Pengurangan Fitur: Kolom Remarks dihapus karena tidak memuat informasi kuantitatif yang konsisten.

3. Statistika Deskriptif

	Mass (MJ)	Radius (RJ)	Period (days)	Semi-major axis (AU)	Temp. (K)[1]	Distance (ly)	Host star mass ($M_{\odot}$)	Host star temp. (K)	Discovery_Year
count	299.000000	2240.000000	2348.000000	1018.000000	104.000000	2291.000000	2101.000000	2340.000000	2367.000000
mean	2.073412	0.262847	77.300830	9.351638	1232.307692	2470.103177	0.954869	5488.815085	2015.265737
std	3.632171	0.275798	459.521698	225.202044	534.782835	1707.256479	0.239216	669.083207	0.964249
min	0.000210	0.042000	0.538354	0.011110	131.000000	4.200000	0.080000	2559.000000	2014.000000
25%	0.085000	0.132000	4.633609	0.057100	822.750000	1437.000000	0.840000	5178.000000	2014.000000
50%	0.729000	0.189000	11.038962	0.098000	1292.000000	2320.000000	0.950000	5636.500000	2016.000000
75%	2.151000	0.255000	26.680536	0.182000	1604.250000	3230.000000	1.070000	5935.000000	2016.000000
max	30.000000	3.400000	11613.000000	6900.000000	2508.000000	27000.000000	3.210000	10500.000000	2016.000000

Dari data ini, bisa di ketahui bahwa banyak sekali data yang memiliki nilai max yang sangat jauh dari rata rata, karena semakin jauh sebuah planet dari titik amat, maka semakin besar data yang dimiliki

3. Identifikasi dataset

	Atribut	Q1	Q3	IQR	Lower Bound	Upper Bound	Jumlah Outlier
0	Mass (MJ)	0.085000	2.151000	2.066000	-3.014000	5.250000	38
1	Radius (RJ)	0.132000	0.255000	0.123000	-0.052500	0.439500	213
2	Period (days)	4.633609	26.680536	22.046927	-28.436783	59.750927	289
3	Semi-major axis (AU)	0.057100	0.182000	0.124900	-0.130250	0.369350	121
4	Temp. (K)[1]	822.750000	1604.250000	781.500000	-349.500000	2776.500000	0
5	Distance (ly)	1437.000000	3230.000000	1793.000000	-1252.500000	5919.500000	37
6	Host star mass ($M_{\odot}$)	0.840000	1.070000	0.230000	0.495000	1.415000	111
7	Host star temp. (K)	5178.000000	5935.000000	757.000000	4042.500000	7070.500000	111

Dari data ini, outlier yang didapatkan cukup banyak, apalagi untuk Radius, Period, Semi-major, dan Host star, namun karena ini Adalah data yang penting, jadi data ini tidak bisa untuk dihapus, disini saya memilih untuk membiarkan

nya karena data data outlier ini merepresentasikan suatu planet yang semakin jauh ataupun planet yang memang memiliki pergerakan yang tidak biasa, dan jika dihapus atau diubah tentu saja akan menghilangkan keunikan dari planet tersebut

-Missing Value:



```
Name 0
Mass (MJ) 2068
Radius (RJ) 127
Period (days) 19
Semi-major axis (AU) 1349
Temp. (K)[1] 2263
Discovery method 0
Distance (ly) 76
Host star mass (M☉) 266
Host star temp. (K) 27
Discovery_Year 0
dtype: int64
```

Pada dataset ini sangat banyak sekali missing value, terutama untuk Mass, Semi-major Axis dan Temperature, ini Adalah hal yang sangat wajar di dunia astronomy dikarenakan semakin jauh exoplanet maka akan semakin susah untuk menghitung massa, temperature dan jarak exoplanet tersebut dari bintangnya, ini disebabkan oleh keterbatasan alat yang dimiliki oleh para pengamat pada tahun tersebut juga


4. Visualisasi :

Dari visualisasi Pairplot dan Heatmap ini, dapat di lihat insightnya :

1. Period (days) vs Semi-major axis (AU) (0,95): Korelasi positif sangat kuat. Semakin jauh jarak eksoplanet ke bintang induknya, semakin lama waktu yang dibutuhkan untuk menyelesaikan satu orbit. Hal ini sejalan dengan Hukum Kepler III.
2. Radius (RJ) vs Temp. (K) (0,80): Korelasi positif kuat. Planet dengan radius besar cenderung memiliki suhu yang lebih tinggi, mengindikasikan dominasi sampel eksoplanet tipe Hot Jupiters.
3. Host star mass (M☉) vs Host star temp. (K) (0,78): Korelasi positif kuat. Bintang induk yang lebih masif secara fisik menghasilkan suhu permukaan yang lebih panas.
4. Temp. (K) vs Host star mass (0,64) & Host star temp. (0,56): Korelasi positif sedang. Radiasi dari bintang yang lebih masif dan panas secara langsung meningkatkan suhu planet di sekitarnya.
5. Period (days) vs Temp. (K) (-0,32): Korelasi negatif sedang. Semakin jauh orbit planet dari bintangnya, suhunya cenderung semakin dingin.



-Distribusi :



bisa dilihat dari distribusinya, beberapa fitur hanya memiliki 1 batang saja dikarenakan outlier yang terlalu tinggi, jadi dari data ini kita bisa untuk menghapus outlier nantinya agar distribusi fitur kontinu ini bisa stabil, dan fitur fitur yang lain cukup stabil sehingga bisa digunakan untuk analisis lanjutan kedepannya

