

Laporan Analisis

Nama: Rasya Gonawi

NRP: 5054251032

1. Deskripsi Dataset

Dataset ini discraping dari website Wikipedia menggunakan requests dan BeautifulSoup. dimana dataset ini Adalah data penemuan eksoplanet (planet di luar tata surya) untuk tahun penemuan 2014 dan 2016, Dataset awal berukuran 2.367 baris dan 12 kolom, yang Dimana setiap kolom Adalah sebagai berikut : Name, Mass (MJ), Radius (RJ), Period (days), Semi-major axis (AU), Temp. (K)[1], Discovery method, Distance (ly), Host star mass ($M_{\odot}$), Host star temp. (K), Remarks, dan Discovery_Year.

2. Data Preprocessing dan Cleaning

tahap pembersihan data memanfaatkan *regular expression* (regex) untuk mengeliminasi karakter anomali. Pembersihan ini secara khusus menargetkan tanda kurung sitasi, teks keterangan, serta simbol plus-minus yang jamak ditemukan pada rentang kesalahan observasi astronomi.

3. Statistika Deskriptif

	Mass (MJ)	Radius (RJ)	Period (days)	Semi-major axis (AU)	Temp. (K)[1]	Distance (ly)	Host star mass ($M_{\odot}$)	Host star temp. (K)	Discovery_Year
count	299.000000	2240.000000	2348.000000	1018.000000	104.000000	2291.000000	2101.000000	2340.000000	2367.000000
mean	2.073412	0.262847	77.300830	9.351638	1232.307692	2470.103177	0.954869	5488.815085	2015.265737
std	3.632171	0.275798	459.521698	225.202044	534.782835	1707.256479	0.239216	669.083207	0.964249
min	0.000210	0.042000	0.538354	0.011110	131.000000	4.200000	0.080000	2559.000000	2014.000000
25%	0.085000	0.132000	4.633609	0.057100	822.750000	1437.000000	0.840000	5178.000000	2014.000000
50%	0.729000	0.189000	11.038962	0.098000	1292.000000	2320.000000	0.950000	5636.500000	2016.000000
75%	2.151000	0.255000	26.680536	0.182000	1604.250000	3230.000000	1.070000	5935.000000	2016.000000
max	30.000000	3.400000	11613.000000	6900.000000	2508.000000	27000.000000	3.210000	10500.000000	2016.000000

Dari data ini, bisa di ketahui bahwa banyak sekali data yang memiliki nilai max yang sangat jauh dari rata rata, karena semakin jauh sebuah planet dari titik amat, maka semakin besar data yang dimiliki. Keterbatasan teleskop dan rasio *signal-to-noise* membuat kita hanya mampu mendeteksi planet pada jarak ribuan tahun cahaya apabila exoplanet tersebut memberikan sinyal yang sangat masif. Kategori *Hot Jupiters* sering mendominasi dataset observasi jarak jauh murni karena ukuran raksasa mereka menutupi cahaya bintang secara signifikan, bukan karena planet kecil tidak eksis di luar sana.

3. Identifikasi dataset

	Atribut	Q1	Q3	IQR	Lower Bound	Upper Bound	Jumlah Outlier
0	Mass (MJ)	0.085000	2.151000	2.066000	-3.014000	5.250000	38
1	Radius (RJ)	0.132000	0.255000	0.123000	-0.052500	0.439500	213
2	Period (days)	4.633609	26.680536	22.046927	-28.436783	59.750927	289
3	Semi-major axis (AU)	0.057100	0.182000	0.124900	-0.130250	0.369350	121
4	Temp. (K)[1]	822.750000	1604.250000	781.500000	-349.500000	2776.500000	0
5	Distance (ly)	1437.000000	3230.000000	1793.000000	-1252.500000	5919.500000	37
6	Host star mass (M _☉)	0.840000	1.070000	0.230000	0.495000	1.415000	111
7	Host star temp. (K)	5178.000000	5935.000000	757.000000	4042.500000	7070.500000	111

Dalam astronomi, outlier pada variabel seperti periode orbit atau jarak ekuatorial merupakan representasi data dari sistem keplanetan yang ekstrem atau memiliki orbit eksentrik. Menghapus data ini berarti membuang penemuan saintifik yang valid. Untuk mengatasi masalah visualisasi di mana grafik distribusi terdistorsi oleh nilai maksimum yang terlalu tinggi, data tidak dibuang. Solusi analitik yang diterapkan adalah transformasi skala logaritmik pada sumbu visualisasi plot data. Skala ini memungkinkan kita melihat distribusi data minor sekaligus mempertahankan nilai ekstrem yang ada di ujung spektrum. Integritas data tetap terjaga, dan korelasi matematis seperti Hukum Kepler Ketiga ($P^2 \propto a^3$) dapat dianalisis dengan lebih presisi.

-Missing Value:


Name	0
Mass (MJ)	2068
Radius (RJ)	127
Period (days)	19
Semi-major axis (AU)	1349
Temp. (K)[1]	2263
Discovery method	0
Distance (ly)	76
Host star mass (M _☉)	266
Host star temp. (K)	27
Discovery_Year	0
dtype: int64	

Banyaknya data kosong atau missing value pada fitur massa dan radius bukan disebabkan oleh kesalahan pencatatan, melainkan limitasi dari instrumen fisika itu sendiri. Mayoritas exoplanet ditemukan melalui metode Transit, yang mengukur peredupan fluks cahaya saat planet melintas di depan bintang. Metode ini sangat presisi untuk mengukur radius fisik, namun tidak mampu mendeteksi massa. Sebaliknya, metode Radial Velocity mengukur efek pergeseran Doppler dari gravitasi planet terhadap bintangnya. Pengukuran ini menghasilkan estimasi massa minimum secara matematis melalui persamaan $M \sin i$, di mana i melambangkan inklinasi orbit, tetapi metode ini buta terhadap parameter radius. Perbedaan prinsip inilah yang menyebabkan data memiliki banyak nilai kosong pada kolom-kolom spesifik.

4. Visualisasi :

Dari visualisasi Pairplot dan Heatmap ini, dapat di lihat insightnya :

1. Period (days) vs Semi-major axis (AU) (0,95): Korelasi positif sangat kuat. Semakin jauh jarak eksoplanet ke bintang induknya, semakin lama waktu yang dibutuhkan untuk menyelesaikan satu orbit. Hal ini sejalan dengan Hukum Kepler III.




2. Radius (RJ) vs Temp. (K) (0,80): Korelasi positif kuat. Planet dengan radius besar cenderung memiliki suhu yang lebih tinggi, mengindikasikan dominasi sampel eksoplanet tipe Hot Jupiters.


3. Host star mass ($M_{\odot}$) vs Host star temp. (K) (0,78): Korelasi positif kuat. Bintang induk yang lebih masif secara fisik menghasilkan suhu permukaan yang lebih panas.

4. Temp. (K) vs Host star mass (0,64) & Host star temp. (0,56): Korelasi positif sedang. Radiasi dari bintang yang lebih masif dan panas secara langsung meningkatkan suhu planet di sekitarnya.

5. Period (days) vs Temp. (K) (-0,32): Korelasi negatif sedang. Semakin jauh orbit planet dari bintangnya, suhunya cenderung semakin dingin.



-Distribusi :



bisa dilihat dari distribusinya, beberapa fitur hanya memiliki 1 batang saja dikarenakan outlier yang terlalu tinggi, jadi dari data ini kita bisa untuk menghapus outlier nantinya agar distribusi fitur kontinu ini bisa stabil, dan fitur fitur yang lain cukup stabil sehingga bisa digunakan untuk analisis lanjutan kedepannya